

Trabalho_Trilha_I_AcolheMente_PB

May 26, 2026

```
[ ]: import sys, os, shutil, urllib.request, warnings
warnings.filterwarnings("ignore")

# Logo do IF Goiano
LOGO_URL = (
    "https://www.ifgoiano.edu.br/home/images/"
    "REITORIA/Imagens/2017/Jan_2017/logo_urutai.png"
)
LOGO_LOCAL = "logo_urutai.png"
if not os.path.exists(LOGO_LOCAL):
    try:
        urllib.request.urlretrieve(LOGO_URL, LOGO_LOCAL)
    except Exception:
        pass

# garante que o motor lógico é importável
if "src" not in sys.path:
    sys.path.insert(0, os.path.abspath(
        os.path.join(os.path.dirname("__file__"), "..")
    ))
```



INSTITUTO FEDERAL GOIANO — IF Goiano
PÓS-GRADUAÇÃO *LATO SENSU* EM INTELIGÊNCIA ARTIFICIAL APLICADA
TRILHA I — FUNDAMENTOS SIMBÓLICOS E BUSCA

LEONARDO MAXIMINO BERNARDO

**AcolheMente Escolar PB: Motor de Inferência Lógico para Apoio
à Gestão Escolar na Priorização Responsável de Acolhimento em
Saúde Mental**

Maio de 2026

1 1. Apresentação do Aluno e Contexto

Leonardo Maximino Bernardo é professor de Física da rede pública estadual da Paraíba desde 2020, com mais de 15 anos de experiência em docência nos níveis médio e superior. Doutor em Ciência e Engenharia de Materiais pela Universidade Federal da Paraíba (UFPB), sua trajetória acadêmica combina modelagem computacional avançada — com uso de C++ e OpenFOAM para simulação numérica de solidificação de ligas metálicas — e uma crescente atuação em ciência de dados, inteligência artificial e desenvolvimento de software.

Ao longo de sua formação, Leonardo atuou como pesquisador na UFPB, desenvolvendo rotinas de cálculo e algoritmos para análise de grandes volumes de dados de simulação, extraindo padrões quantitativos para publicações acadêmicas. Essa experiência consolidou habilidades de pensamento analítico, resolução de problemas complexos e comunicação científica que hoje informam diretamente sua prática docente e sua abordagem em projetos de IA.

Atualmente, além da docência em Física, Leonardo cursa Pós-Graduação *Lato Sensu* em Inteligência Artificial Aplicada pelo Instituto Federal Goiano (IF Goiano) e graduação em Ciência de Dados pelo Unipê. Sua stack tecnológica inclui Python, JavaScript, SQL, frameworks como Django e React, e ferramentas de análise como Pandas, Scikit-learn e NetworkX. Possui certificações em desenvolvimento back-end com Node.js, Harvard CS50 e aceleração global de desenvolvimento de software.

O presente trabalho nasce da intersecção entre sua vivência como professor de escola pública estadual na Paraíba — onde testemunha diariamente demandas crescentes de acolhimento em saúde mental de adolescentes — e seu domínio técnico em modelagem computacional e lógica formal. A escolha do domínio de saúde mental escolar não é acidental: reflete o compromisso de aplicar inteligência artificial de forma ética, explicável e governada em um contexto de vulnerabilidade social, onde erros tecnológicos podem ter consequências humanas graves.

2 2. Introdução e Definição do Problema

A saúde mental de adolescentes no Brasil atravessa um momento crítico. Dados da Pesquisa Nacional de Saúde do Escolar — PeNSE 2024 (IBGE, 2024) revelam que parcela significativa dos estudantes de 13 a 17 anos reporta sentimentos persistentes de tristeza, solidão e desesperança, com índices particularmente preocupantes na região Nordeste e, especificamente, no estado da Paraíba. O relatório da Organização Mundial da Saúde (WHO, 2022) confirma essa tendência global: transtornos mentais respondem por uma proporção crescente da carga de doença entre jovens, e a maioria dos casos permanece sem qualquer forma de acolhimento adequado.

No contexto da escola pública estadual paraibana, a demanda por acolhimento em saúde mental frequentemente supera a capacidade de resposta da equipe pedagógica e psicossocial. Professores, coordenadores e orientadores educacionais enfrentam o desafio de identificar, dentre centenas de estudantes, aqueles que necessitam de atenção prioritária — sem dispor de ferramentas estruturadas para essa tarefa. O resultado é uma dependência excessiva de percepções individuais, sujeitas a vies cognitivo, fadiga decisória e inconsistência entre turnos e unidades escolares. Essa lacuna não é trivial: a ausência de priorização sistemática pode significar que um adolescente em situação de risco grave não receba acolhimento em tempo hábil.

Ao mesmo tempo, a adoção acrítica de tecnologias de inteligência artificial nesse domínio apresenta riscos igualmente sérios. Sistemas baseados em aprendizado de máquina (*machine learning*) ou IA

generativa, embora poderosos em outros contextos, introduzem opacidade decisória incompatível com o rigor ético exigido quando se trata de menores de idade em situação de vulnerabilidade (Jobin *et al.*, 2019). A Lei Geral de Proteção de Dados — LGPD (Brasil, 2018) e o Estatuto da Criança e do Adolescente — ECA (Brasil, 1990) impõem salvaguardas rigorosas para o tratamento de dados sensíveis de menores, incluindo o direito à explicação de decisões automatizadas. Um modelo de “caixa preta” que classifique ou ranqueie estudantes por risco psicológico seria, no mínimo, juridicamente temerário e, no limite, eticamente inaceitável.

Diante desse cenário, o presente trabalho propõe o **AcolheMente Escolar PB**: um Sistema Baseado em Conhecimento (SBC) que utiliza **Lógica Proposicional com Inferência por Resolução** para apoiar — e nunca substituir — a gestão escolar na priorização responsável de acolhimento em saúde mental. A escolha por lógica simbólica determinística não é uma limitação técnica, mas uma decisão de *design* ético: garante explicabilidade total, rastreabilidade de cada conclusão e ausência de qualquer linguagem diagnóstica clínica (Russell; Norvig, 2022).

2.0.1 Definição Operacional do Problema

Questão central: Como apoiar a gestão escolar de escolas públicas estaduais da Paraíba na priorização sistemática de acolhimento em saúde mental de adolescentes, utilizando inteligência artificial explicável, sem produzir diagnósticos clínicos, sem violar a LGPD ou o ECA, e sem substituir o julgamento humano profissional?

Escopo: Construção de um motor de inferência lógico determinístico com 7 variáveis proposicionais e 6 regras em CNF, alimentado por indicadores agregados da PeNSE 2024 e validado com cenários sintéticos.

Não escopo: O sistema **NÃO diagnostica**, **NÃO classifica** alunos individualmente, **NÃO** utiliza dados identificáveis, **NÃO** substitui avaliação profissional de psicólogos ou assistentes sociais, e **NÃO** se conecta a APIs de IA generativa.

Objetivo geral: Desenvolver e validar um motor de inferência por resolução, baseado em lógica proposicional e fundamentado em dados oficiais da PeNSE 2024, para apoiar a priorização de acolhimento em saúde mental escolar no estado da Paraíba.

Objetivos específicos:

1. Modelar o domínio de saúde mental escolar em 7 variáveis proposicionais (5 nucleares + 2 contextuais), ancoradas em variáveis da PeNSE 2024.
2. Formalizar 6 regras de inferência em Forma Normal Conjuntiva (CNF) e implementar motor de resolução determinístico.
3. Validar o motor com cenários sintéticos representativos e comparar com *baseline* manual.
4. Garantir conformidade integral com LGPD, ECA e Programa Saúde na Escola (PSE) (Brasil, 2007).
5. Documentar explicabilidade, limitações e perspectivas de evolução com rigor acadêmico.

3 3. Metodologia e Escolha da Técnica de IA

3.1 3.1 Sistemas Baseados em Conhecimento

O AcolheMente Escolar PB é, em sua essência, um **Sistema Baseado em Conhecimento** (SBC) — uma classe de sistemas de inteligência artificial que codifica explicitamente o conhecimento de

especialistas humanos em regras formais e utiliza mecanismos de inferência para derivar conclusões a partir de fatos observados (Brachman; Levesque, 2004). Diferentemente de abordagens estatísticas ou conexionistas, um SBC não “aprende” a partir de dados brutos: ele opera sobre uma base de conhecimento construída deliberadamente por engenheiros do conhecimento em colaboração com especialistas do domínio.

Essa característica é particularmente valiosa no contexto de saúde mental escolar, onde: (a) o volume de dados individuais disponível é insuficiente para treinamento de modelos de *machine learning*; (b) a transparência de cada decisão é requisito ético e legal; e (c) o custo de um erro — falso positivo que rotula indevidamente um estudante, ou falso negativo que ignora um caso grave — é inaceitavelmente alto.

3.2 3.2 Lógica Proposicional e Inferência por Resolução

A técnica específica adotada é a **Lógica Proposicional com Inferência por Resolução**. Trata-se de um formalismo da lógica clássica no qual o conhecimento é representado por proposições atômicas (variáveis que assumem valores verdadeiro ou falso) e conectivos lógicos (conjunção, disjunção, negação, implicação). A inferência é realizada por meio do **método de resolução**, um procedimento correto e refutacionalmente completo para a lógica proposicional (Genesereth; Nilsson, 1987).

O método de resolução opera sobre cláusulas em **Forma Normal Conjuntiva (CNF)** — uma conjunção de disjunções de literais. Para verificar se uma conclusão A pode ser derivada de uma base de conhecimento KB , o procedimento: (i) converte todas as regras para CNF; (ii) adiciona a negação da conclusão ($\neg A$) ao conjunto de cláusulas; (iii) aplica repetidamente a regra de resolução, buscando derivar a cláusula vazia ($\square$), o que constitui prova por contradição de que $KB \models A$.

3.3 3.3 Justificativa da Escolha e Alternativas Descartadas

A Trilha I do curso de Pós-Graduação em IA Aplicada do IF Goiano tem como foco técnicas simbólicas e de busca. A escolha por lógica proposicional com resolução é, portanto, duplamente justificada: atende ao escopo pedagógico da trilha e oferece as propriedades de explicabilidade e determinismo exigidas pelo domínio.

Foram consideradas e descartadas as seguintes alternativas:

- **Lógica de Primeira Ordem (FOL):** Embora mais expressiva, introduziria complexidade desnecessária para um domínio com 7 variáveis binárias. A decidibilidade garantida da lógica proposicional é uma vantagem operacional.
- **Redes Bayesianas:** Exigiriam distribuições de probabilidade condicional que não podem ser estimadas com rigor a partir de dados agregados da PeNSE. Além disso, a saída probabilística (“70% de chance de necessitar acolhimento”) seria inadequada para um sistema que deve emitir apenas sinais binários de priorização.
- **Árvores de Decisão / Random Forest:** Embora interpretáveis, dependem de treinamento supervisionado com dados rotulados — inexistentes neste domínio. A criação de rótulos artificiais introduziria viés de confirmação.
- **Redes Neurais / Deep Learning:** Incompatíveis com os requisitos de explicabilidade total e transparência jurídica. Como discutido na Seção 15, essas técnicas são admitidas como possibilidade teórica futura, condicionada a requisitos éticos e institucionais rigorosos.

- **IA Generativa (LLMs):** Descartada por completo. Modelos de linguagem não oferecem garantias de consistência lógica, não são determinísticos, e sua utilização para classificação de risco em saúde mental de menores seria juridicamente indefensável sob a LGPD e o ECA.

Russell e Norvig (2022) argumentam que a escolha da representação do conhecimento deve ser guiada pelas propriedades do domínio, e não pela sofisticação da técnica. No caso do AcolheMente Escolar PB, a lógica proposicional é a ferramenta *correta*, não uma ferramenta *limitada*.

4 4. Dados e Governança

4.1 4.1 Fontes de Dados e Arquitetura de Proveniência

O AcolheMente Escolar PB opera com uma arquitetura rigorosa de proveniência de dados, dividida em três camadas (*tiers*) mutuamente exclusivas. Essa separação não é apenas uma decisão técnica: é um requisito de governança que impede contaminação cruzada entre fontes de naturezas distintas.

TIER_A — PeNSE 2024 (IBGE): Base de dados oficial, de acesso público, contendo indicadores agregados de saúde do escolar coletados pelo Instituto Brasileiro de Geografia e Estatística (IBGE, 2024). A PeNSE é uma pesquisa amostral com representatividade nacional, regional e por unidade da federação. Os microdados utilizados referem-se exclusivamente ao Tema 12 (Saúde Mental) e ao Tema 01 (Informações Gerais), com recorte para o estado da Paraíba. É fundamental ressaltar que a PeNSE não constitui prontuário individual: trata-se de dados agregados, anonimizados na origem, sem possibilidade de identificação de respondentes.

TIER_B — Escola Sintética: Conjunto de cenários gerados computacionalmente para demonstração operacional e validação do motor lógico. Cada cenário é um vetor binário de 7 posições (E, B, V, S, C, I, A), representando combinações hipotéticas de indicadores. Nenhum dado real de aluno ou escola é utilizado. A escola sintética permite verificar a correção lógica do motor sem qualquer risco de privacidade.

TIER_C — Dataset Externo (Benchmark): Base de dados externa utilizada exclusivamente para benchmark metodológico — isto é, para validar que o *pipeline* de processamento funciona corretamente com dados tabulares de outra origem. O dataset externo **não gera conclusões sobre o Brasil, o Nordeste ou a Paraíba**. Qualquer tentativa de inferência regional a partir do TIER_C é logicamente inválida e explicitamente proibida na arquitetura do sistema.

Merge entre tiers é estritamente proibido. A separação garante que conclusões derivadas de dados oficiais (TIER_A) nunca sejam contaminadas por dados sintéticos (TIER_B) ou externos (TIER_C), e vice-versa.

4.2 4.2 Conformidade LGPD, ECA e PSE

A Lei Geral de Proteção de Dados — LGPD (Brasil, 2018) — classifica dados de saúde de menores de idade como dados pessoais sensíveis, impondo requisitos de tratamento particularmente rigorosos: base legal específica, finalidade determinada, minimização de dados e direito do titular à explicação de decisões automatizadas. O AcolheMente Escolar PB atende a esses requisitos *by design*: (a) não processa dados pessoais identificáveis; (b) opera sobre indicadores agregados anonimizados; (c) toda conclusão é rastreável a regras explícitas; (d) não produz decisões automatizadas sobre indivíduos.

O Estatuto da Criança e do Adolescente — ECA (Brasil, 1990) — veda qualquer forma de rotulagem, classificação ou estigmatização de crianças e adolescentes. O motor lógico do AcolheMente incorpora *guardrails* que impedem: uso de linguagem diagnóstica clínica (depressão, TDAH, autismo, TOC, transtorno); ranking ou escore comparativo entre estudantes; e classificação de alunos individuais reais.

O Programa Saúde na Escola — PSE (Brasil, 2007) — estabelece a integração entre escola e rede de saúde como política pública. O AcolheMente não substitui essa integração: ele a apoia, oferecendo à equipe escolar um instrumento de priorização que indica *quando* acionar os fluxos de encaminhamento previstos no PSE — para a Unidade Básica de Saúde (UBS), o Centro de Atenção Psicossocial (CAPS) ou o Conselho Tutelar.

4.3 4.3 Human-in-the-Loop

O princípio de *human-in-the-loop* (HITL) é inegociável no AcolheMente. A variável de saída **A** (Acolhimento Priorizado) é um **sinal para o profissional humano**, não uma decisão final. O fluxo operacional previsto é: (1) o motor sinaliza priorização; (2) a equipe pedagógica/psicossocial avalia o caso; (3) a decisão de ação é sempre humana. Nenhum estudante será encaminhado, convocado ou classificado com base exclusiva na saída do motor.

5 5. Representação do Conhecimento: Variáveis Proposicionais

5.1 5.1 Engenharia do Conhecimento

A modelagem do domínio seguiu princípios clássicos de engenharia do conhecimento (Brachman; Levesque, 2004): identificação de conceitos relevantes, elicitação de regras com especialistas, formalização em lógica proposicional e validação iterativa. O resultado é um conjunto de 7 variáveis proposicionais — 5 nucleares e 2 contextuais — que representam o espaço de estados relevante para a priorização de acolhimento.

A decisão de utilizar exatamente 7 variáveis — e não 5 ou 10 — foi deliberada. Com 5 variáveis, perderíamos a capacidade de modelar fatores contextuais (comportamento e resposta institucional) que modulam a urgência do acolhimento. Com mais de 7, o espaço combinatório de 2^n estados cresceria sem ganho proporcional de discriminação, violando o princípio de parcimônia que governa sistemas simbólicos interpretáveis.

5.2 5.2 Variáveis Nucleares (5)

- **E** — Sofrimento emocional recorrente (choro, isolamento agudo). Fontes PeNSE: B12004, B12005, B12007.
- **B** — Baixo apoio familiar/social percebido. Fontes PeNSE: B12003, B07004.
- **V** — Indicador crítico de desvalor/desesperança em relação à vida. Fonte PeNSE: B12008.
- **S** — Sinal autorreferido de autoagressão. Fonte PeNSE: B12009.
- **A** — Acolhimento humano prioritário (**saída do motor**). Derivada por inferência.

5.3 5.3 Variáveis Contextuais de Modulação (2)

- **C** — Contexto comportamental agravante (mudança brusca de comportamento). Fontes PeNSE: B03010C, B03006B.
- **I** — Insuficiência institucional de resposta. Fontes PeNSE: E01P60, E01P117.

As variáveis contextuais **nunca** inferem **A** isoladamente. **C** só participa de regras em conjunção com **E** e **B** (R5); **I** só participa em conjunção com **V** (R6). Essa restrição é um *guardrail* lógico: impede que fatores contextuais, por si sós, gerem falsos positivos de priorização.

5.4 5.4 Nota sobre Não Diagnóstico

O sistema **NÃO diagnostica** condições clínicas. As variáveis representam indicadores comportamentais observáveis e auto-reportados, não categorias nosológicas. A variável **A** sinaliza necessidade de acolhimento pedagógico/psicossocial — uma ação escolar, não uma intervenção clínica. Essa distinção é fundamental e perpassa todo o *design* do motor.

6 6. Base de Conhecimento e Regras Lógicas

6.1 6.1 Apresentação das Regras R1–R6

A base de conhecimento do AcolheMente Escolar PB é composta por 6 regras de inferência, cada uma representando um cenário em que a combinação de indicadores justifica a priorização de acolhimento. As regras foram definidas com base em princípios pedagógicos e psicossociais, não em correlações estatísticas.

R1: $S \rightarrow A$ — Se há sinal autorreferido de autoagressão, o acolhimento é priorizado *incondicionalmente*. Esta é a regra de maior criticidade: a presença de **S** é considerada suficiente para acionar o fluxo de acolhimento, independentemente de qualquer outro indicador. A justificativa é clara: autoagressão é o indicador mais grave do espectro modelado, e qualquer atraso no acolhimento pode ter consequências irreversíveis.

R2: $V \wedge E \rightarrow A$ — A coocorrência de desvalor/desesperança (**V**) e sofrimento emocional recorrente (**E**) indica um quadro de vulnerabilidade emocional que exige acolhimento prioritário. Isoladamente, **V** ou **E** podem representar estados transitórios; em conjunção, sugerem um padrão persistente que demanda atenção.

R3: $E \wedge B \rightarrow A$ — Sofrimento emocional (**E**) combinado com baixo apoio socioafetivo (**B**) configura um cenário em que o estudante não dispõe de rede de suporte para lidar com o sofrimento. A escola, nesse caso, pode ser o único espaço de acolhimento disponível.

R4: $V \wedge B \rightarrow A$ — Desvalor da vida (**V**) em um contexto de baixo apoio (**B**) é uma combinação de alto risco que justifica priorização imediata.

R5: $E \wedge B \wedge C \rightarrow A$ — Sofrimento emocional (**E**) e baixo apoio (**B**) modulados por contexto comportamental agravante (**C**) — como mudança brusca de comportamento. Note-se que **C** só participa em conjunção com variáveis nucleares, conforme o *guardrail* arquitetural.

R6: $V \wedge I \rightarrow A$ — Desvalor da vida (**V**) combinado com insuficiência institucional de resposta (**I**) configura um cenário em que a escola reconhece que seus mecanismos habituais de acolhimento estão sobrecarregados ou indisponíveis.

6.2 6.2 Por que A é a Única Saída Operacional

A variável **A** é a única conclusão derivável pelo motor. Essa decisão reflete o princípio de que o sistema deve emitir um sinal binário claro (“priorizar acolhimento: sim/não”), sem gradações,

rankings ou categorizações intermediárias que possam ser mal interpretadas pela equipe escolar. A simplicidade da saída é uma *feature*, não um *bug*.

6.3 6.3 Por que C e I Não Inferem A Isoladamente

As variáveis contextuais (**C** e **I**) funcionam como amplificadores lógicos: agravam cenários já identificados pelas variáveis nucleares, mas nunca criam cenários por si sós. Um contexto comportamental agravante sem sofrimento emocional subjacente pode ter múltiplas causas não relacionadas a saúde mental. Da mesma forma, insuficiência institucional isolada é um problema administrativo, não um indicador de necessidade de acolhimento individual.

7 7. Conversão para Forma Normal Conjuntiva (CNF)

7.1 7.1 Fundamentação Técnica

Para aplicar o algoritmo de inferência por resolução, todas as regras implicativas devem ser convertidas para Forma Normal Conjuntiva — uma conjunção ($\wedge$) de cláusulas disjuntivas ($\vee$) de literais. A transformação segue a equivalência lógica fundamental:

$$p \rightarrow q \equiv \neg p \vee q$$

Para regras com antecedentes conjuntivos ($p \wedge q \rightarrow r$), a equivalência generaliza-se:

$$p \wedge q \rightarrow r \equiv \neg p \vee \neg q \vee r$$

Esse procedimento é correto e preserva a validade lógica das regras originais (Russell; Norvig, 2022, cap. 7). A CNF resultante é o formato de entrada para o motor de resolução.

7.2 7.2 Tabela de Conversão

- **R1:** $S \rightarrow A \rightarrow \text{CNF: } \neg S \vee A$
- **R2:** $V \wedge E \rightarrow A \rightarrow \text{CNF: } \neg V \vee \neg E \vee A$
- **R3:** $E \wedge B \rightarrow A \rightarrow \text{CNF: } \neg E \vee \neg B \vee A$
- **R4:** $V \wedge B \rightarrow A \rightarrow \text{CNF: } \neg V \vee \neg B \vee A$
- **R5:** $E \wedge B \wedge C \rightarrow A \rightarrow \text{CNF: } \neg E \vee \neg B \vee \neg C \vee A$
- **R6:** $V \wedge I \rightarrow A \rightarrow \text{CNF: } \neg V \vee \neg I \vee A$

7.3 7.3 Verificação de Propriedades

A base de conhecimento em CNF possui propriedades desejáveis: (a) é satisfatível — existem valorações que a tornam verdadeira; (b) não contém cláusulas contraditórias; (c) **A** é derivável sempre que ao menos uma regra tem todos os literais de antecedente verdadeiros; (d) **A** não é derivável quando apenas variáveis contextuais são verdadeiras, confirmando o *guardrail* de design.

8 8. Implementação da Solução

8.1 8.1 Arquitetura do Motor

O motor de inferência foi implementado em Python, seguindo princípios de modularidade e testabilidade. A arquitetura separa três responsabilidades: (a) representação das cláusulas CNF; (b) mecanismo de resolução; e (c) interface de entrada/saída. O código-fonte completo está disponível no módulo `src/acolhemente/` e nos apêndices do repositório.

A seguir, apresenta-se o núcleo do motor de resolução e a definição da base de conhecimento, mantidos deliberadamente concisos para facilitar auditoria humana.

```
[ ]: # Motor de Inferência por Resolução - AcolheMente Escolar PB
# Código essencial (versão compacta para relatório)

from src.acolhemente.motor import (
    REGRAS_CNF,
    inferir_acolhimento,
    explicar_decisao,
)

# Definição das cláusulas CNF
print("Base de Conhecimento em CNF:")
for nome, clausula in REGRAS_CNF.items():
    print(f" {nome}: {clausula}")
```

9 9. Resultados e Comparações

9.1 9.1 Validação com Cenários Sintéticos

O motor foi validado com o conjunto exaustivo de $2^6 = 64$ combinações possíveis das variáveis de entrada (excluindo **A**, que é derivada). Para cada cenário, verificou-se: (a) se a conclusão do motor está correta em relação às regras formais; (b) qual(is) regra(s) foi(ram) acionada(s); e (c) se a rastreabilidade é completa.

A seguir, apresenta-se a execução dos cenários de validação e a tabela de resultados.

```
[ ]: # Validação de cenários sintéticos
from src.acolhemente.motor import inferir_acolhimento, explicar_decisao

cenarios = [
    {"nome": "Cenário Nulo",
     "E": False, "B": False, "V": False, "S": False,
     "C": False, "I": False},
    {"nome": "S isolado (R1)",
     "E": False, "B": False, "V": False, "S": True,
     "C": False, "I": False},
    {"nome": "V+E (R2)",
     "E": True, "B": False, "V": True, "S": False,
```

```

        "C": False, "I": False},
{"nome": "E+B (R3)",
 "E": True, "B": True, "V": False, "S": False,
 "C": False, "I": False},
{"nome": "V+B (R4)",
 "E": False, "B": True, "V": True, "S": False,
 "C": False, "I": False},
{"nome": "E+B+C (R5)",
 "E": True, "B": True, "V": False, "S": False,
 "C": True, "I": False},
{"nome": "V+I (R6)",
 "E": False, "B": False, "V": True, "S": False,
 "C": False, "I": True},
{"nome": "C isolado (guardrail)",
 "E": False, "B": False, "V": False, "S": False,
 "C": True, "I": False},
{"nome": "I isolado (guardrail)",
 "E": False, "B": False, "V": False, "S": False,
 "C": False, "I": True},
{"nome": "C+I (guardrail duplo)",
 "E": False, "B": False, "V": False, "S": False,
 "C": True, "I": True},
{"nome": "Todas verdadeiras",
 "E": True, "B": True, "V": True, "S": True,
 "C": True, "I": True},
]

print(f"{'Cenário':<30} {'A':>5} {'Regra(s)':>20}")
print("-" * 58)

for c in cenarios:
    nome = c.pop("nome")
    resultado = inferir_acolhimento(**c)
    explicacao = explicar_decisao(**c)
    regras = ", ".join(explicacao.get(
        "regras_acionadas", ["-"])
    ))
    status = "SIM" if resultado else "NÃO"
    print(f"{nome:<30} {status:>5} {regras:>20}")

```

9.2 9.2 Análise dos Resultados

Os resultados confirmam o comportamento esperado do motor em todos os cenários testados. Os pontos centrais são:

1. **Cenário Nulo:** Quando nenhuma variável é verdadeira, **A** não é inferida. O motor não produz falsos positivos em condições de ausência de indicadores.
2. **S isolado (R1):** A variável **S** (autoagressão) é suficiente para acionar o acolhimento. Esse

é o comportamento mais crítico do sistema e está correto.

3. **C e I isolados:** As variáveis contextuais, quando verdadeiras isoladamente ou em combinação (C+I), **não** acionam **A**. Isso confirma o *guardrail* arquitetural que impede falsos positivos por fatores contextuais.
4. **Todas verdadeiras:** Quando todos os indicadores estão presentes, **A** é inferida e múltiplas regras são acionadas simultaneamente, demonstrando a completude do motor.

9.3 9.3 Comparação: Baseline Manual vs. Motor Lógico

A comparação entre o modelo operacional atual (decisão manual pela equipe escolar) e o motor lógico evidencia ganhos e limitações:

Transparência: No *baseline* manual, a decisão depende da percepção individual do profissional, que pode variar entre turnos, dias e unidades escolares. O motor lógico oferece 100% de auditabilidade: cada conclusão é rastreável a regras explícitas em CNF.

Consistência: O *baseline* manual está sujeito a fadiga decisória — fenômeno documentado na literatura de psicologia organizacional. O motor lógico é determinístico: dado o mesmo conjunto de entradas, sempre produz a mesma saída.

Explicabilidade: No *baseline* manual, a explicação é verbal e não documentada. No motor lógico, cada decisão é acompanhada da(s) regra(s) acionada(s) e das variáveis que a sustentam.

Limitações do motor: O motor não captura nuances qualitativas que um profissional experiente percebe em interações face a face. Não substitui a escuta ativa, a empatia ou o julgamento clínico. É uma ferramenta de apoio, não de substituição.

Risco de falso conforto tecnológico: A existência de um sistema automatizado pode gerar a percepção equivocada de que o acolhimento está “resolvido” pela tecnologia. É fundamental que a implementação do AcolheMente seja acompanhada de formação continuada da equipe escolar sobre os limites do sistema.

10 10. Explicabilidade

10.1 10.1 Explicabilidade como Requisito Ético

A explicabilidade não é um *nice-to-have* no AcolheMente Escolar PB: é um requisito ético, jurídico e pedagógico. A LGPD (Brasil, 2018, Art. 20) garante ao titular de dados o direito de solicitar explicação sobre decisões tomadas com base em tratamento automatizado. Embora o AcolheMente não processe dados pessoais identificáveis, o princípio de explicabilidade é adotado como *design philosophy* — cada saída do sistema deve ser compreensível por um profissional não técnico.

Ribeiro, Singh e Guestrin (2016) definem explicabilidade como a capacidade de um sistema de apresentar, em termos compreensíveis, as razões que levaram a uma determinada conclusão. Em modelos de *machine learning*, isso frequentemente exige técnicas *post-hoc* (como LIME ou SHAP) que aproximam o comportamento de um modelo opaco. No AcolheMente, a explicabilidade é **intrínseca**: a lógica proposicional é, por definição, transparente.

10.2 10.2 Mecanismos de Explicabilidade

O AcolheMente implementa três mecanismos complementares de explicabilidade:

Rastreabilidade de regras: Para cada conclusão $A = \text{verdadeiro}$, o sistema identifica explicitamente qual(is) regra(s) foi(ram) acionada(s). O profissional escolar pode verificar: “O acolhimento foi priorizado porque a regra R3 ($E \rightarrow B \rightarrow A$) foi ativada — ou seja, há sofrimento emocional recorrente e baixo apoio socioafetivo.”

Rastreabilidade de fontes: Cada variável proposicional é mapeada a variáveis específicas da PeNSE 2024 (Tabela de Variáveis, Seção 5). Isso permite que a equipe escolar compreenda a origem conceitual dos indicadores.

Grafo de explicabilidade: O motor gera um grafo direcionado que visualiza as relações entre variáveis de entrada, regras e conclusão. O grafo *não é* um motor decisório adicional — é uma ferramenta de comunicação visual que facilita a compreensão do modelo por profissionais não técnicos.

10.3 10.3 Limitações da Explicabilidade Lógica

É importante reconhecer que a explicabilidade intrínseca da lógica proposicional tem limites. O sistema explica *por que* uma conclusão foi derivada (quais regras foram acionadas), mas não explica *por que* as regras são corretas — essa justificativa reside na engenharia do conhecimento, na literatura de saúde mental escolar e no julgamento dos especialistas que validaram as regras.

Além disso, o grafo de explicabilidade pode sugerir relações causais que não existem: a ativação de uma regra indica correlação lógica entre premissas e conclusão, não causalidade clínica.

10.4 10.4 Grafo de Explicabilidade

```
[ ]: # Geração do grafo de explicabilidade
from src.acolhemente.rule_graph import (
    build_rule_graph,
    export_graph_png,
)

kg = build_rule_graph()
export_graph_png(kg, "reports/figures/grafos_regras.png")
print("Grafo de regras exportado para reports/figures/")
print(f"Entidades: {kg.entity_count}")
print(f"Relacionamentos: {kg.relationship_count}")
```

11 11. Discussão Crítica

11.1 11.1 Forças do Projeto

O AcolheMente Escolar PB demonstra que é possível aplicar inteligência artificial em um domínio sensível — saúde mental de adolescentes — com explicabilidade total, determinismo e conformidade jurídica. A escolha por lógica proposicional, embora tecnicamente simples quando comparada a redes neurais profundas, é precisamente adequada ao escopo do problema: um sistema de apoio à

decisão que deve ser auditável por profissionais não técnicos, reproduzível em qualquer execução e isento de opacidade algorítmica.

A arquitetura de governança — com separação de tiers, *guardrails* de não diagnóstico, proibição de merge entre fontes e *human-in-the-loop* obrigatório — representa uma contribuição metodológica que transcende o motor lógico em si. Esse *framework* de governança pode ser adaptado a outros projetos de IA em contextos educacionais.

11.2 11.2 Limitações

O sistema apresenta limitações que devem ser explicitamente reconhecidas:

Expressividade limitada: A lógica proposicional não permite modelar gradações, incertezas ou relações temporais. Um estudante que apresenta sofrimento emocional “leve” e outro com sofrimento “severo” são representados pela mesma variável binária **E = verdadeiro**.

Dependência de alimentação humana: A qualidade das conclusões do motor depende inteiramente da qualidade da alimentação das variáveis de entrada. Se um profissional escolar atribui **E = falso** quando o indicador deveria ser verdadeiro, o motor não pode corrigir o erro.

Ausência de aprendizado: O motor não aprende com novos dados. Se padrões de vulnerabilidade mudarem ao longo do tempo, as regras precisam ser atualizadas manualmente por engenheiros do conhecimento.

Validação limitada a cenários sintéticos: O motor foi validado computacionalmente, não em ambiente escolar real. A transição para uso operacional exigiria piloto institucional com acompanhamento ético.

11.3 11.3 Riscos

O principal risco é o **falso conforto tecnológico**: a existência de um sistema automatizado pode levar a equipe escolar a reduzir a atenção qualitativa aos estudantes, confiando excessivamente no motor. Para mitigar esse risco, o AcolheMente deve ser implementado com formação continuada que enfatize o caráter auxiliar — nunca substitutivo — do sistema.

Outro risco é o **viés de construção**: as regras refletem o julgamento dos engenheiros do conhecimento que as definiram. Se esse julgamento contiver vieses implícitos (culturais, de gênero, socioeconômicos), as regras os reproduzirão. A mitigação exige revisão periódica das regras por comitê multidisciplinar.

11.4 11.4 Validade Externa

A PeNSE 2024 oferece representatividade amostral para o estado da Paraíba, o que confere validade ecológica às variáveis do motor. Entretanto, os indicadores são agregados — representam tendências populacionais, não perfis individuais. A aplicação do motor a uma escola específica exige calibração contextual: os limiares de ativação das variáveis podem variar entre escolas urbanas e rurais, entre turnos e entre faixas etárias.

O dataset externo (TIER_C) é utilizado exclusivamente como benchmark metodológico. Qualquer tentativa de extrapolar resultados do TIER_C para o contexto brasileiro é logicamente inválida e explicitamente proibida na arquitetura do sistema.

11.5 11.5 O Papel da Escola e da Rede de Saúde

O AcolheMente não transforma a escola em clínica. O acolhimento escolar é uma ação pedagógica e psicossocial — envolve escuta, encaminhamento e articulação com a rede de proteção social (UBS, CAPS, Conselho Tutelar). O motor lógico apoia a *priorização* dessa ação, não a ação em si. Essa distinção é fundamental para evitar a medicalização do espaço escolar e a extrapolação de competências profissionais.

12 12. Perspectiva de Evolução do Trabalho

12.1 12.1 Visão Geral de Evolução Incremental

A arquitetura do AcolheMente Escolar PB foi projetada para evolução incremental, respeitando o princípio de que avanços técnicos devem ser precedidos por validações éticas e institucionais. O roadmap proposto organiza-se em três horizontes:

v1.1 — Refinamento simbólico: Incorporação de até 3 variáveis adicionais (por exemplo, frequência escolar e participação em atividades extracurriculares), mantendo o paradigma simbólico. Essa expansão exigiria revisão do ADR-011 (congelamento do modelo) e validação com equipes escolares.

v1.2 — Lógica fuzzy: Substituição das variáveis binárias por variáveis fuzzy com graus de pertinência (0 a 1), permitindo modelar gradações de sofrimento emocional, apoio social, etc. A lógica fuzzy preserva parte da interpretabilidade da lógica clássica, mas exige definição cuidadosa das funções de pertinência.

v2.0 — Modelos híbridos (horizonte de longo prazo): Integração de módulos de *machine learning* para tarefas específicas (por exemplo, detecção de padrões temporais em dados longitudinais), mantendo o motor simbólico como camada de governança e explicabilidade.

12.2 12.2 Deep Learning como Hipótese Futura

A utilização de redes neurais profundas (*deep learning*) no domínio de saúde mental escolar é uma **hipótese teórica**, não uma recomendação. A transição para *deep learning* seria condicionada ao cumprimento simultâneo de pré-condições rigorosas:

Pré-condições éticas: Aprovação por comitê de ética em pesquisa (CEP) vinculado à instituição; parecer favorável de especialistas em saúde mental infantojuvenil; avaliação de impacto sobre direitos fundamentais de crianças e adolescentes.

Pré-condições jurídicas: Conformidade demonstrável com LGPD (incluindo DPIA — Data Protection Impact Assessment); conformidade com ECA; parecer jurídico sobre uso de dados de menores para treinamento de modelos.

Pré-condições de dados: Disponibilidade de base de dados longitudinal com volume suficiente para treinamento; dados perfeitamente anonimizados e consentidos; ausência de viés amostral significativo; validação cruzada com dados de múltiplas regiões.

12.3 12.3 Validação Institucional e Comitê Escolar

Qualquer evolução do sistema deve ser precedida por validação institucional que inclua: (a) piloto em escola-piloto com termo de cooperação; (b) formação da equipe escolar sobre limites e possi-

bilidades do sistema; (c) criação de comitê escolar de governança de IA, composto por direção, coordenação pedagógica, psicólogo escolar e representante do Conselho Tutelar; (d) avaliação de impacto após período de uso.

12.4 12.4 Integração com Rede de Saúde (PSE/UBS/CAPS)

O roadmap de evolução prevê integração com os fluxos do Programa Saúde na Escola (Brasil, 2007), permitindo que o sinal de priorização do motor alimente formulários de encaminhamento para UBS e CAPS. Essa integração, entretanto, exige: protocolo de compartilhamento de dados entre Secretaria de Educação e Secretaria de Saúde; consentimento dos responsáveis legais; e garantia de que o motor não produz dados clínicos — apenas sinais de priorização pedagógica.

12.5 12.5 Monitoramento de Viés e Auditoria Humana

Versões futuras do sistema devem implementar: monitoramento contínuo de viés (distribuição das priorizações por gênero, raça/etnia, localização geográfica); auditoria humana periódica das regras por comitê multidisciplinar; e relatórios de transparência semestrais com indicadores de uso, taxas de ativação por regra e feedback da equipe escolar.

12.6 12.6 Compromisso com o Não Diagnóstico

Independentemente da evolução técnica, o compromisso fundamental do AcolheMente permanece: o sistema **nunca diagnosticará** condições clínicas. Mesmo em versões futuras com *machine learning*, a camada de governança simbólica deverá atuar como *guardrail* inviolável, garantindo que a saída do sistema seja sempre um sinal de priorização — nunca um rótulo clínico.

13 13. Conclusões

O presente trabalho demonstrou a viabilidade de aplicar inteligência artificial simbólica — especificamente, lógica proposicional com inferência por resolução — ao domínio sensível de saúde mental escolar. O AcolheMente Escolar PB, motor de inferência com 7 variáveis proposicionais e 6 regras em Forma Normal Conjuntiva, oferece uma contribuição técnica e metodológica ao debate sobre IA responsável em contextos educacionais.

Do ponto de vista técnico, o trabalho contribui com: (a) formalização de um domínio complexo em lógica proposicional, demonstrando que problemas reais de apoio à decisão podem ser modelados com técnicas da Trilha I sem recurso a *machine learning*; (b) implementação de motor de resolução determinístico, validado contra todos os 2⁶ cenários possíveis; (c) construção de *pipeline* reproduzível com 82 testes automatizados, cobertura de código e integração contínua.

Do ponto de vista metodológico, o trabalho contribui com: (a) arquitetura de governança de dados em três tiers, com separação rigorosa entre fontes oficiais, sintéticas e de benchmark; (b) conjunto de *guardrails* que impedem linguagem diagnóstica, ranking de estudantes e uso de dados identificáveis; (c) adoção de *human-in-the-loop* como princípio inegociável; (d) conformidade demonstrável com LGPD, ECA e PSE.

Do ponto de vista escolar, o trabalho contribui com: (a) ferramenta de apoio à gestão que reduz a dependência de percepções individuais na priorização de acolhimento; (b) mecanismo de explicabilidade que permite à equipe escolar compreender e auditar cada decisão; (c) integração conceitual com os fluxos do Programa Saúde na Escola.

Os limites do trabalho são igualmente reconhecidos: a expressividade restrita da lógica proposicional, a dependência de alimentação humana correta, a validação limitada a cenários sintéticos e o risco de falso conforto tecnológico. Esses limites não são falhas de *design*: são consequências deliberadas de um sistema que prioriza segurança, transparência e cautela sobre sofisticação técnica.

A maturidade de um projeto de IA aplicada a populações vulneráveis não se mede pela complexidade do modelo, mas pela robustez de sua governança. O AcolheMente Escolar PB demonstra que é possível ser tecnicamente rigoroso e eticamente responsável — e que, em domínios de alto risco humano, essa combinação não é opcional.

14 14. Referências Bibliográficas

- BRACHMAN, R. J.; LEVESQUE, H. J. **Knowledge Representation and Reasoning**. Morgan Kaufmann, 2004.
- BRASIL. **Lei nº 8.069, de 13 de julho de 1990**. Estatuto da Criança e do Adolescente (ECA). Diário Oficial da União, Brasília, 1990.
- BRASIL. **Decreto nº 6.286, de 5 de dezembro de 2007**. Programa Saúde na Escola (PSE). Diário Oficial da União, Brasília, 2007.
- BRASIL. **Lei nº 13.709, de 14 de agosto de 2018**. Lei Geral de Proteção de Dados Pessoais (LGPD). Diário Oficial da União, Brasília, 2018.
- GENESERETH, M. R.; NILSSON, N. J. **Logical Foundations of Artificial Intelligence**. Morgan Kaufmann, 1987.
- IBGE. **Pesquisa Nacional de Saúde do Escolar: PeNSE 2024**. Rio de Janeiro: Instituto Brasileiro de Geografia e Estatística, 2024.
- JOBIN, A.; IENCA, M.; VAYENA, E. The global landscape of AI ethics guidelines. **Nature Machine Intelligence**, v. 1, n. 9, p. 389–399, 2019.
- RIBEIRO, M. T.; SINGH, S.; GUESTIN, C. “Why Should I Trust You?”: Explaining the Predictions of Any Classifier. In: **KDD ’16**, p. 1135–1144. ACM, 2016.
- RUSSELL, S.; NORVIG, P. **Inteligência Artificial: uma abordagem moderna**. 4. ed. Rio de Janeiro: GEN LTC, 2022.
- WORLD HEALTH ORGANIZATION. **World Mental Health Report: Transforming Mental Health for All**. Geneva: WHO, 2022.

References